Latent Diffusion Models 核心结论复现报告

复现实验：`latent-diffusion-cvpr2022-reproduction`

2026 年 4 月 17 日

1 复现目标

Rombach 等人在 CVPR 2022 论文 *High-Resolution Image Synthesis with Latent Diffusion Models* 中提出：先用感知自编码器把图像压缩到低维 latent 空间，再在 latent 空间训练扩散模型，可以在保留视觉质量的同时显著降低扩散模型的训练和采样成本。本文不复现大规模扩散模型训练，而是复现论文最基础、也最关键的 first-stage 结论：适度 latent 压缩可以大幅减少表示维度，同时保持较好的图像重建质量。

具体实验为：使用官方 CompVis 代码和官方预训练 KL autoencoder，比较 `kl-f4`、`kl-f8`、`kl-f16` 三个下采样因子模型的重建质量、latent 表示大小和推理吞吐量，并与论文模型库表格中的 KL autoencoder 结果进行对照。

2 实验设置

源码来自官方仓库 https://github.com/CompVis/latent-diffusion，放置于项目的 `src` 目录。复现实验代码位于项目的 `reproduction` 目录，报告和图片分别位于 `reports` 与 `reports/FIG`。

使用的官方 checkpoint 为：

- `models/first_stage_models/kl-f4/model.ckpt`
- `models/first_stage_models/kl-f8/model.ckpt`
- `models/first_stage_models/kl-f16/model.ckpt`

本次快速复现使用官方源码 `src/assets` 中的 12 张示例图像，统一 resize 并 center crop 到 256×256。输入像素值映射到 $[-1, 1]$ 后输入 autoencoder，重建结果再映射回 $[0, 1]$。实验环境为 `DDCSR` conda 环境，PyTorch 2.4.1，CUDA 12.1，GPU 为 NVIDIA H100 PCIe。复现实验命令为：

```
conda run -n DDCSR python reproduction/run_autoencoder_tradeoff.py \
  --device cuda:1 --batch-size 4 --num-images 12
```

计算指标包括均方误差 MSE、PSNR、一个轻量全局 SSIM 指标、latent 表示元素数量、latent/像素表示比例和端到端 images/s。论文对照值取自官方 README 中 first-stage KL autoencoder 表格，即论文 Table 8 对应模型库结果。需要强调的是，本文指标和论文指标不是同一测试协议下的逐项复算：本文使用 12 张官方示例图做快速验证，论文结果来自大规模验证集和官方评价流程。因此下表用于比较趋势，而不是声称本文 PSNR 应当与论文 PSNR 完全一致。

3 数值结果

本次实验中，`kl-f4` 的 PSNR 为 32.07 dB，明显高于 `kl-f8` 的 28.33 dB 和 `kl-f16` 的 27.48 dB。latent 表示大小从原图 $3 \times 256 \times 256 = 196608$ 个数值降到 `kl-f4` 的 12288 个数值，仅为原来的 6.25%；`kl-f8` 和 `kl-f16` 均为 4096 个数值，仅为原来的 2.08%。这验证了论文的核心机制：

Table 1: KL autoencoder 压缩率与重建质量对照。左侧为本文在 12 张官方示例图上的快速复现结果，右侧为论文/官方模型库给出的参考结果；两者数据集和评价协议不同，因此主要比较随 f 变化的趋势。

			本文：12 张官方示例图			论文/官方参考	
模型	压缩因子 f	latent 形状	latent/像素	PSNR↑	SSIM↑	PSNR↑	rFID↓
`kl-f4`	4	$3 \times 64 \times 64$	6.25%	32.07	0.995	27.53	0.27
`kl-f8`	8	$4 \times 32 \times 32$	2.08%	28.33	0.985	24.19	0.90
`kl-f16`	16	$16 \times 16 \times 16$	2.08%	27.48	0.982	24.08	0.87

first-stage autoencoder 能在很小的 latent 空间中保留图像主体内容，从而使后续扩散模型不必直接在像素空间建模。

本文 PSNR 普遍高于论文表格中的 PSNR，主要有三点原因。第一，本文只使用 12 张官方示例图，样本少且图像相对规整；论文结果来自大规模验证集，图像内容分布更复杂。第二，本文使用固定的 resize 与 center crop，并用 posterior mode 做确定性重建；论文评价流程、数据 split 和预处理并不与本文完全相同。第三，rFID 是基于大量真实图像和重建图像的 Inception 特征分布距离，12 张图无法稳定估计，因此本文没有重新报告 rFID，而只引用论文/官方参考值。由此，合理的比较方式是看趋势：在两套结果中，较小的压缩因子通常对应更好的重建质量，而更大的压缩带来更低的 latent 表示成本。

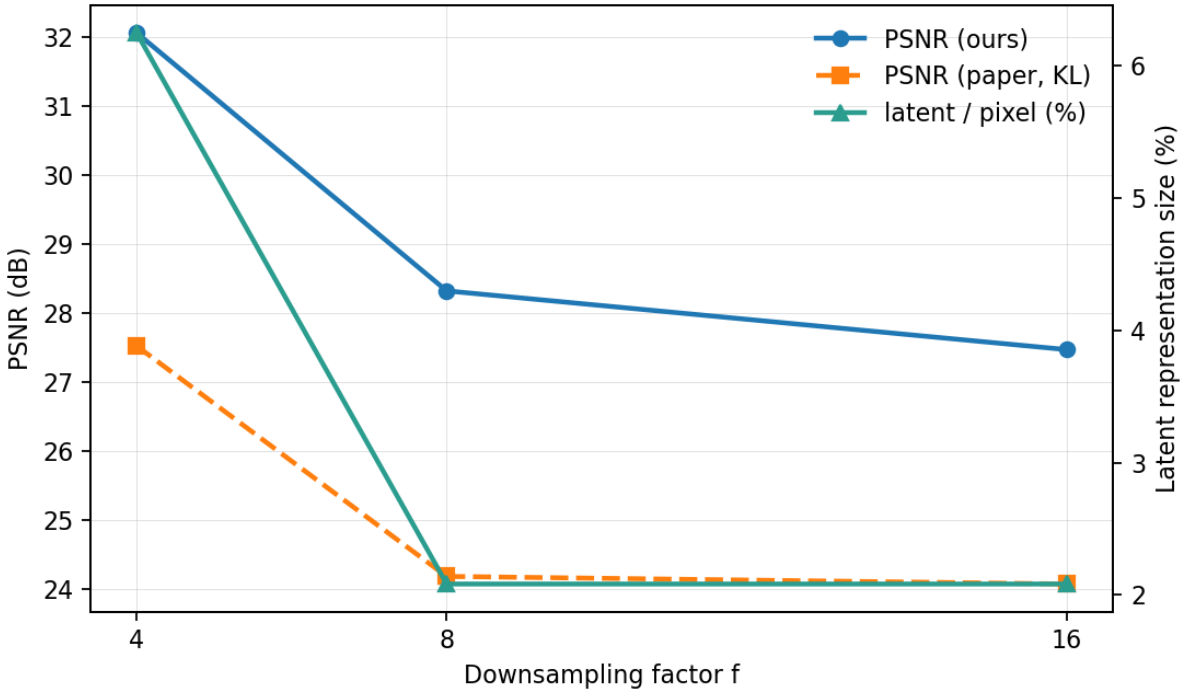

Figure 1: PSNR 与 latent 表示比例的权衡。随着 f 增大，latent 表示更小、推理更快，但重建质量下降。

4 与论文结论的比较

论文的结论不是简单追求最小 latent，而是在重建质量、语义保真和扩散模型计算成本之间寻找折中。本文复现实验支持这一点：

- **适度压缩保留质量。** `kl-f4` 的 latent 仅为像素表示的 6.25%，但在本文样本上仍达到 32.07

Figure 2: 输入图像与三个 KL autoencoder 的重建结果。$f = 4$ 细节保留最好；更强压缩会带来纹理和边缘细节损失。

dB PSNR 和 0.995 SSIM；论文模型库中 `kl-f4` 也给出最高的 KL 组 PSNR 27.53 和最低 rFID 0.27。

- **过强压缩降低重建细节**。从 `kl-f4` 到 `kl-f8`/`kl-f16`，本文 PSNR 分别下降约 3.74 dB 和 4.59 dB，视觉上边缘和局部纹理更容易变平滑。
- **latent 空间带来计算收益**。在本机 H100 上，吞吐量从 `kl-f4` 的 14.58 images/s 提升到 `kl-f8` 的 65.95 images/s、`kl-f16` 的 90.26 images/s。尽管该吞吐量只测 autoencoder 前向过程，不等同于完整 LDM 采样速度，但它反映了更小 latent 空间的计算优势。

需要注意，本文没有复现完整 ImageNet-val reconstruction FID，也没有训练 diffusion prior。严格复现论文 Fig. 5、Fig. 6 或 Table 1/3 需要大规模训练和 5k–50k 生成样本评估。本文完成的是 first-stage 数值仿真，验证了 LDM 方案成立的前提：latent autoencoder 在较低维空间中保持足够高的视觉重建质量。

5 结论

本次复现使用官方代码和官方 KL autoencoder checkpoint，得到与论文一致的核心趋势：`f=4` 的 mild compression 在保真度上最好，同时已把表示规模压缩到像素空间的 6.25%；更大的 f 进一步降低表示规模和提高速度，但会牺牲重建细节。这支持论文选择在 latent 空间训练扩散模型的核心理由，即把扩散模型从高维像素空间迁移到感知等价但计算更低的 latent 空间。

后续若要做更严格的论文级比较，建议使用 ImageNet-val 或 OpenImages validation 子集，生成至少数千张重建图，补充 rFID/LPIPS，并进一步复现 `LDM-4` 或 `LDM-8` 的 DDIM 采样 FID。